

基于软件定义成像的暗光目标检测

王晶

摘要

暗光目标检测是智能驾驶、夜间监控和端侧视觉感知中的关键问题。然而，在低照度条件下，图像通常受到低信噪比、低对比度、颜色偏移、运动模糊和暗部细节缺失等退化影响，导致目标边界、局部纹理和语义判别特征被显著破坏。现有方法主要从检测网络改进、低光图像增强或 RAW 感知模型适配角度进行补偿，但大多默认相机成像流程是固定的前处理模块，难以避免传统 ISP 在暗光条件下对任务相关信息的压缩、平滑或失真。本文从软件定义成像角度重新审视暗光目标检测，提出一种面向检测任务的闭环成像优化框架 SDI-Det。该框架将相机硬件控制、Camera ISP 参数调节和下游目标检测反馈统一建模为任务驱动优化问题，并利用强化学习 Agent 自适应搜索成像参数，使 RAW-to-RGB 转换过程直接服务于检测性能。进一步地，本文设计渐进式奖励调度和分组搜索约束，以缓解高维成像参数空间带来的训练不稳定和搜索成本。实验在 Raw COCO 合成 RAW 数据集与 LOD 真实暗光 RAW 数据集上进行验证。结果表明，SDI-Det 在 Raw COCO 上取得 36.5 mAP，在 LOD 上取得 71.4 mAP，均优于 Dark-YOLO、RAW-Adapter 和 AdaptiveISP 等代表性方法。实验结果说明，暗光检测的性能瓶颈不仅存在于后端检测网络，也存在于成像前端；通过软件定义方式对成像过程进行任务反馈式优化，可以从源头提升暗光目标的可检测性。

1 引言

目标检测是自动驾驶、机器人导航、视频监控和移动端智能感知中的基础任务。近年来，基于深度神经网络的检测器在常规 sRGB 图像上取得了显著进展。然而，当视觉系统部署到夜间、弱照明、背光或高速运动等复杂场景中时，检测性能仍会明显下降。与正常光照图像相比，暗光图像不仅亮度不足，而且通常伴随低信噪比、低局部对比度、颜色失真、运动模糊和纹理丢失。这些退化会直接破坏目标的边界结构和局部判别特征，使检测模型更容易出现漏检、误检和定位偏差。ExDark 和 LOD 等低光检测数据集已经表明，暗光退化并不是简单的亮度缩放，而会系统性改变目标外观、背景分布和检测特征表达 [1, 2]。

现有暗光目标检测方法大体可以分为三类。第一类方法从检测网络本身出发，通过改进 backbone、neck、head 或特征融合结构提升低光鲁棒性。第二类方法在检测器之前加入低光增强、去噪或图像复原模块，以提高输入图像的可见性，例如 Retinexformer 等低光增强方法在多个增强 benchmark 上取得了较强结果 [3]。第三类方法开始利用 RAW 图像或可学习 ISP，将传统相机成像过程中的部分模块替换为任务感知的神经网络。RAW-Adapter、Dark-ISP、Beyond RGB 和 TA-ISP 等近期工作表明，RAW-to-RGB 转换不应只是固定的人眼视觉前处理，而可以被重新设计为面向检测或分割任务的可学习前端 [11, 14, 15, 17]。上述方法在一定程度上缓解了暗光退化，但仍存在一个共同限制：它们通常将相机成像过程视为固定或半固定的前端，而不是一个可根据下游任务反馈主动优化的系统。

本文认为，暗光目标检测不应仅被建模为“给定退化图像后的鲁棒识别问题”，而应被建模为“成像系统与视觉任务之间的协同优化问题”。在暗光条件下，曝光时间、传感器增益、读出方式、去噪强度、去马赛克、白平衡、颜色校正、伽马校正和色调映射等成像参数都会影响目标信息是否被保留。如果相机 ISP 仍以人眼视觉质量或固定经验规则为目标，则最终输出的 sRGB 图像未必最适合目标检测。相反，面向机器视觉的成像系统应当根据检测任务反馈动态调节成像策略，使输出图像在目标边界保留、噪声抑制、局部对比度增强和纹理保持之间形成任务友好的折中。

基于上述观察，本文提出一种基于软件定义成像的暗光目标检测框架 SDI-Det。该框架将暗光 RAW 输入、相机硬件控制、Camera ISP 参数和目标检测网络连接为闭环优化系统。具体而言，强化学习 Agent 根据 RAW 图像统计、图像元数据、历史动作和检测反馈，选择合适的硬件控制与 ISP 参数；随后，检测网络对成像结果进行预测，并将检测质量、图像约束和计算代价共同反馈给 Agent。通过该闭环过程，成像模块不再是检测网络之前的固定前处理，而成为可由任务目标定义和优化的主动感知前端。本文的主要贡献可以概括为：将暗光目标检测重新表述为任务驱动的软件定义成像问题；提出统一硬件控制、ISP 参数和检测反馈的闭环强化学习框架；设计渐进式奖励调度和分组搜索约束，以提升训练稳定性并降低搜索成本；在合成 RAW 和真实暗光 RAW 数据上验证了方法有效性。

2 相关工作

暗光目标检测的核心困难来自成像退化对检测特征的系统性破坏。低照度条件下，传感器接收到的有效光子数减少，图像信号容易被读出噪声、散粒噪声和量化误差淹没。同时，由于曝光时间、增益和运动状态之间存在耦合，暗光图像往往同时呈现噪声放大、模糊增强和颜色偏移。ExDark 提供了跨 10 种低光条件、12 类目标的暗光检测数据，LOD 则进一步面向极低光场景构建真实数据和低光合成流程 [1, 2]。这些数据集推动了暗光检测从普通 RGB 检测向低照度鲁棒感知发展。近期也有工作继续从检测网络侧或图像自适应处理侧改进低光鲁棒性，例如 IA-YOLO 通过可微图像处理模块为检测器自适应增强输入图像，ERUP-YOLO 进一步使用统一的图像自适应滤波增强恶劣天气下的检测鲁棒性 [4, 5]。这类方法直接服务于检测任务，但其主要操作对象仍是 ISP 输出后的 RGB 图像，因此难以恢复 RAW 阶段已经损失的信息。

低光增强方法通常希望将暗图像恢复为视觉上更清晰、更明亮的图像。典型方法包括基于 Retinex 理论的光照-反射分解、基于 GAN 或 diffusion 的图像生成，以及基于 Transformer 的全局增强。Retinexformer 将低光增强建模为一阶段 Retinex 框架，并使用 illumination-guided Transformer 捕获长程依赖，在多个低光增强 benchmark 上取得强性能 [3]。然而，低光增强的优化目标通常是重建误差、感知质量或人眼视觉指标，而不是检测 mAP。对于目标检测任务，视觉质量提升并不必然带来检测性能提升。过强的亮度增强可能放大暗部噪声，过强的去噪可能抹除小目标纹理，局部对比度增强也可能引入伪影并干扰检测特征。因此，面向检测的图像处理应当由下游任务反馈驱动，而不是单纯追求视觉自然性。

RAW 感知视觉与任务感知 ISP 为暗光检测提供了更接近成像源头的解决思路。RAW 图像保留了传感器采集到的原始线性响应，通常具有更高位深和更少后处理压缩，因此在暗光场景中包含更多关于暗部结构、噪声分布和曝光状态的信息。Learning to See in the Dark 证明，直接在短曝光 RAW 上学习低光成像 pipeline 可以有效缓解传统相机处理流程在极暗条件下的噪声放大和误差累积问题 [6]。近期 RAW-Adapter 将 learnable ISP stages 作为 input-level adapter，并在

模型内部加入 model-level adapter, 以适配 sRGB 预训练模型到 RAW 输入 [11]; 其后续版本进一步提出 RAW-Bench, 用 17 类 RAW corruption 评估 RAW 感知模型的鲁棒性 [12]。这些工作说明, RAW 域不只是图像复原的输入格式, 也可以成为高层视觉任务的有效信息源。

任务感知 ISP 进一步将 RAW-to-RGB 转换从固定前处理转变为可训练或可搜索模块。ReconfigISP 通过可微代理和架构搜索, 使 ISP 结构和参数能够针对数据、传感器和任务自动调整 [8]。DRL-ISP 将 ISP 工具箱和多目标任务奖励结合起来, 用强化学习迭代选择 ISP tool, 以服务 RAW-to-RGB restoration、2D object detection 和 monocular depth estimation 等任务 [9]。AdaptiveISP 则进一步将线性图像输入映射为自适应 ISP pipeline 和参数, 并以检测性能为目标进行深度强化学习优化 [10]。与这些方法相比, 本文更强调暗光检测中的系统级闭环: 不仅调整 ISP pipeline 内部参数, 也将相机硬件控制、图像元数据和检测反馈纳入统一策略。

近年来, RAW 检测 benchmark 和 RAW 任务前端的发展进一步强化了本文问题设置的必要性。AODRaw 提供 7,785 张真实高分辨率 RAW 图像、135,601 个实例和 62 类标注, 覆盖 9 种光照和天气条件, 为 RAW/sRGB 检测评估提供了更系统的基准 [13]。Dark-ISP 面向低光检测提出轻量自适应 ISP plugin, 直接处理 Bayer RAW 图像并支持端到端检测训练 [14]。Beyond RGB 使用并行 RAW adaptation module 替代传统串行 ISP, 以更充分保留面向检测的 RAW 信息 [15]。CRM-IR 则提出从 RAW 学习 compact metadata 来指导低光 sRGB refinement, 以降低 RAW 存储和传输成本 [16]。TA-ISP 使用全局、区域和像素尺度的轻量 modulation operators 生成任务导向表示, 强调在资源受限部署场景下的任务感知 RAW-to-RGB 处理 [17]。更进一步, RAWild 和 RAWDet-7 分别关注跨传感器 RAW 检测泛化与量化 RAW 检测/描述 benchmark, 说明 RAW 视觉正在从单一低光增强问题扩展到多传感器、低比特和多任务感知问题 [18, 19]。

软件定义成像的核心思想是: 成像系统不应由固定硬件配置和固定 ISP 参数决定, 而应能够根据任务需求动态调整。对于机器视觉任务而言, 最优图像不一定是人眼看来最自然的图像, 而是能够最大化下游感知性能的任务友好表示。真实相机系统和 ISP pipeline 中存在大量离散模块、非线性处理和不可微硬件接口, 例如曝光、增益、读出模式、去噪强度、白平衡增益和色调映射曲线。Hardware-in-the-loop ISP 优化表明, 可以将真实硬件 ISP 直接纳入端到端任务损失优化, 并通过零阶随机优化绕开不可微硬件接口 [7]。因此, 强化学习和硬件在环优化共同为本文的闭环软件定义成像提供了方法依据。

3 方法

3.1 问题定义与总体框架

给定一张暗光 RAW 图像 $x \in \mathcal{X}_{raw}$, 传统相机系统通过固定 ISP 函数 I_θ 将其映射为 sRGB 图像:

$$y = I_\theta(x), \quad (1)$$

其中 θ 表示固定 ISP 参数, $y \in \mathcal{X}_{rgb}$ 表示输出图像。随后, 目标检测器 $D(\cdot)$ 在 y 上预测目标边界框、类别和置信度:

$$\hat{o} = D(y), \quad \hat{o} = \{\hat{b}, \hat{c}, \hat{s}\}. \quad (2)$$

该范式将成像过程与检测任务解耦, 其隐含假设是固定 ISP 生成的图像同时适合人眼观看和机器检测。然而, 在暗光场景中, 这一假设并不总成立。固定 ISP 可能为了视觉平滑而过度去噪, 也可能为了整体亮度而压缩局部对比度, 从而削弱检测器所需的边界和纹理信息。

本文将成像过程重新定义为任务驱动的可优化映射。设 h 表示相机硬件控制参数，例如曝光时间、模拟增益、数字增益、读出模式、帧率和感兴趣区域；设 θ 表示 ISP 参数，例如去噪强度、白平衡增益、颜色校正矩阵、伽马曲线和色调映射参数。软件定义成像的目标是寻找一组任务友好的成像参数：

$$(h^*, \theta^*) = \arg \max_{h, \theta} \mathcal{R}(D(I_\theta(x; h))), \quad (3)$$

其中 $\mathcal{R}(\cdot)$ 表示由检测质量、图像约束和计算代价共同构成的奖励函数。与传统 ISP 不同，本文优化的目标不是单独的图像视觉质量，而是最终检测性能。

SDI-Det 的总体框架包含状态编码器、强化学习 Agent、可调成像模块和目标检测网络。系统首先从暗光 RAW 图像中提取亮度分布、局部对比度、噪声估计、曝光元数据和历史成像参数；随后，强化学习 Agent 根据当前状态输出成像动作，该动作同时包含硬件控制指令和 ISP 参数调整；然后，可调成像模块根据动作对 RAW 图像进行处理，生成面向检测任务的 RGB 图像或中间视觉表示；最后，目标检测网络对成像结果进行预测，并将检测质量反馈给 Agent。该过程形成如下闭环：

$$x \rightarrow s_t \rightarrow a_t \rightarrow (h_t, \theta_t) \rightarrow y_t \rightarrow D(y_t) \rightarrow R_t. \quad (4)$$

3.2 强化学习闭环优化

在第 t 个决策步，Agent 接收状态 s_t 。本文将状态定义为：

$$s_t = \Phi(x, m, h_{t-1}, \theta_{t-1}, q_{t-1}), \quad (5)$$

其中 x 为 RAW 输入， m 为相机元数据， h_{t-1} 和 θ_{t-1} 分别表示上一时刻的硬件参数和 ISP 参数， q_{t-1} 表示上一轮检测反馈， $\Phi(\cdot)$ 为状态编码函数。状态设计需要同时包含成像信息和任务信息。成像信息用于描述当前图像是否欠曝、过曝、噪声过强或颜色偏移；任务信息用于描述检测器是否能够稳定识别目标。

策略网络 π_ϕ 根据状态选择动作：

$$a_t \sim \pi_\phi(a_t | s_t), \quad (6)$$

其中 ϕ 为策略参数。动作空间由硬件动作和 ISP 动作组成：

$$a_t = [a_t^h, a_t^\theta]. \quad (7)$$

其中 a_t^h 控制曝光、增益、读出方式和帧率等硬件变量， a_t^θ 控制去噪、白平衡、颜色校正、伽马校正和色调映射等 ISP 变量。执行动作后，系统更新成像参数：

$$h_t = h_{t-1} + \Delta h(a_t^h), \quad \theta_t = \theta_{t-1} + \Delta \theta(a_t^\theta). \quad (8)$$

该设计使 Agent 不仅能在图像后处理阶段调整视觉效果，也能在 RAW 信号采集和转换阶段影响目标信息保留。对于暗光检测而言，这一点尤其重要，因为很多目标信息在进入 sRGB 图像之前就已经受到曝光、增益和 ISP 参数的影响。

为了使成像结果同时满足检测性能、成像稳定性和计算效率，本文设计如下奖励函数：

$$R_t = \lambda_t R_{\text{det}} + (1 - \lambda_t) R_{\text{img}} - \beta R_{\text{cost}}. \quad (9)$$

其中, R_{det} 表示检测奖励, 可由 mAP、召回率、检测置信度或定位质量构造; R_{img} 表示图像约束, 用于抑制过曝、欠曝、颜色严重偏移和噪声放大; R_{cost} 表示计算代价或硬件控制代价; λ_t 控制检测奖励与图像约束之间的权重; β 控制成本惩罚强度。该奖励函数避免 Agent 只追求图像变亮或只追求图像平滑, 而是促使成像参数在亮度、噪声、对比度和目标结构之间取得任务友好的折中。最终, 策略通过最大化累计奖励进行优化:

$$\max_{\phi} \mathbb{E}_{\pi_{\phi}} \left[\sum_{t=1}^T \gamma^{t-1} R_t \right], \quad (10)$$

其中 γ 为折扣因子, T 为最大决策步数。

3.3 渐进式训练与分组搜索

直接使用检测奖励训练成像 Agent 可能导致早期策略不稳定。原因在于, 训练初期 Agent 尚未学会基本成像规律, 若检测奖励权重过高, 策略可能通过过度曝光、过度锐化或异常色调映射获得短期检测收益, 但破坏整体成像稳定性。为此, 本文采用渐进式奖励调度, 将检测奖励权重定义为:

$$\lambda_t = \lambda_{\min} + (\lambda_{\max} - \lambda_{\min}) \cdot \sigma(k(t - t_0)), \quad (11)$$

其中 $\sigma(\cdot)$ 为 Sigmoid 函数, $\lambda_{\min}$ 和 $\lambda_{\max}$ 分别表示检测奖励权重的下界和上界, t_0 表示任务奖励增强的起始阶段, k 控制增长速度。在训练早期, 模型主要学习稳定成像, 避免生成严重过曝、欠曝或颜色异常的图像; 在训练后期, 检测奖励逐渐占据主导, 使成像策略更直接地服务于目标检测。

Camera ISP 通常包含大量可调参数。如果共有 N 个参数, 每个参数有 K 种候选取值, 则原始搜索空间规模为:

$$\Omega_{\text{origin}} = K^N. \quad (12)$$

该空间随参数数量指数增长, 直接搜索会带来高计算成本和低采样效率。为降低优化难度, 本文将成像参数划分为 G 个功能组, 例如曝光/增益组、去噪/锐化组、颜色/白平衡组和色调映射组。分组后, Agent 在每个子空间中分别搜索, 并逐步组合得到整体策略。近似搜索规模可表示为:

$$\Omega_{\text{group}} = G \times \left(\frac{K}{G} \right)^{\frac{N}{G}}. \quad (13)$$

该约束将全局高维搜索拆解为多个低维子问题, 从而降低参数组合数量。更重要的是, 分组搜索符合 ISP pipeline 的结构先验: 曝光和增益主要影响全局亮度与噪声水平, 颜色校正主要影响类别相关颜色分布, 去噪和锐化主要影响局部纹理与边缘。利用这种结构划分, 可以使 Agent 更高效地学习成像参数与检测性能之间的关系。

4 实验

4.1 实验设置

本文使用 LOD、Raw COCO 和 OnePlus 三类数据评估 SDI-Det 的有效性。LOD 数据集包含真实相机采集的暗光图像和目标检测标注, 覆盖 8 类目标, 能够反映真实暗光场景中的噪声、颜色偏移和细节缺失问题 [2]。Raw COCO 数据集从 COCO 图像通过逆 ISP 或合成 RAW 退化

流程生成，类别分布更丰富，适合验证方法在多类别检测场景中的泛化能力 [20]。OnePlus 数据集来自手机传感器采集的真实夜间驾驶场景，包含 3 类目标，用于分析软件定义成像在移动端真实传感器条件下的应用潜力 [8]。

本文选取三类代表性方法进行比较。Dark-YOLO 代表检测网络改进式路线，主要通过调整 YOLO-style 检测器来适应暗光图像，反映了只在后端检测网络侧进行补偿的性能 [21]。RAW-Adapter 代表 RAW 感知适配路线，通过可学习 RAW 输入模块或 adapter 将 RAW 数据接入视觉模型，反映了利用 RAW 信息但不显式进行闭环硬件-ISP 优化的性能 [11]。AdaptiveISP 代表任务驱动 ISP 优化路线，通过自适应方式为下游视觉任务调整 ISP pipeline 或参数，是与本文最接近的 baseline [10]。本文方法 SDI-Det 进一步将相机硬件控制、Camera ISP 参数和目标检测反馈统一纳入闭环强化学习框架，从成像源头优化暗光检测性能。

本文采用 mAP 作为主要评价指标。mAP 同时衡量目标分类准确性和边界框定位质量，是目标检测任务中的标准指标。除数值结果外，本文还报告典型检测可视化结果，用于分析不同方法在暗光场景中的目标边界保留、弱纹理识别和多目标定位能力。

4.2 主实验结果

Raw COCO 数据集上的实验结果如表 1 所示。Dark-YOLO 取得 19.6 mAP，说明仅依赖检测网络改进难以充分补偿合成暗光 RAW 场景中的成像退化。RAW-Adapter 将结果提升至 22.0 mAP，表明引入 RAW 信息能够带来一定收益。AdaptiveISP 进一步达到 30.0 mAP，说明任务驱动 ISP 优化明显优于单纯检测网络修改或 RAW 输入适配。相比之下，SDI-Det 取得 36.5 mAP，相比 AdaptiveISP 提升 6.5 个百分点。该结果说明，将硬件控制、ISP 参数和检测反馈统一建模可以更有效地提升暗光目标检测性能。

表 1: Raw COCO 数据集上的目标检测结果。

方法类别	方法	mAP
检测网络改进	Dark-YOLO	19.6
RAW 感知适配	RAW-Adapter	22.0
任务驱动 ISP	AdaptiveISP	30.0
软件定义成像	SDI-Det	36.5

LOD 数据集上的实验结果如表 2 所示。Dark-YOLO 和 RAW-Adapter 分别取得 60.3 和 61.5 mAP，说明在真实暗光 RAW 数据中，单纯网络改进和 RAW 适配的提升有限。AdaptiveISP 达到 65.4 mAP，验证了任务感知 ISP 在真实低光场景中的有效性。SDI-Det 取得 71.4 mAP，相比 AdaptiveISP 提升 6.0 个百分点。该结果表明，本文方法不仅在合成 RAW 设置中有效，也能迁移到真实暗光数据，并稳定提升检测性能。

表 2: LOD 数据集上的目标检测结果。

方法类别	方法	mAP
检测网络改进	Dark-YOLO	60.3
RAW 感知适配	RAW-Adapter	61.5
任务驱动 ISP	AdaptiveISP	65.4
软件定义成像	SDI-Det	71.4

从两个数据集的结果可以看出，性能提升主要来自两个方面。第一，软件定义成像能够在 RAW-to-RGB 转换之前保留更多目标相关信息，减少固定 ISP 对暗部细节的不可逆损失。第二，任务反馈使成像参数不再单纯追求视觉质量，而是面向检测器需要的边界、纹理和局部对比度进行优化。

4.3 消融实验与可视化分析

为验证各模块的有效性，本文在 Raw COCO 和 LOD 数据集上进行消融实验，结果如表 3 所示。固定 ISP 表示不进行成像参数自适应调节；仅 ISP 参数搜索表示保持硬件参数固定，只优化去噪、白平衡、颜色校正和色调映射等 ISP 参数；无渐进式训练表示直接使用检测奖励训练 Agent；无分组搜索约束表示在完整高维参数空间中直接搜索；完整 SDI-Det 则同时使用硬件控制、ISP 参数搜索、渐进式训练和分组搜索约束。

表 3: 不同模块对暗光目标检测性能的影响。

方法设置	Raw COCO mAP	LOD mAP	相对搜索成本
固定 ISP	24.6	60.9	1.0×
仅 ISP 参数搜索	31.7	66.0	1.6×
无渐进式训练	33.8	68.1	1.8×
无分组搜索约束	36.1	70.8	3.7×
完整 SDI-Det	36.5	71.4	1.9×

从表 3 可以看到，仅 ISP 参数搜索相比固定 ISP 已经带来明显提升，说明暗光检测的性能瓶颈不仅来自检测网络，也来自 RAW-to-RGB 成像过程。进一步引入硬件控制后，完整 SDI-Det 在两个数据集上均取得最优结果，表明曝光、增益等采集端参数能够与 ISP 参数形成互补，从源头提高目标区域的有效信息量。无渐进式训练的性能低于完整模型，说明直接使用检测奖励容易导致早期策略不稳定；而无分组搜索约束虽然性能接近完整模型，但搜索成本显著增加，说明分组搜索能够在较小代价下获得接近最优的成像策略。可视化结果进一步表明，SDI-Det 并不简单追求整体亮度提升，而是更倾向于保留目标区域的边界和局部纹理。在低光 bicycle 场景中，本文方法能够增强车轮和车架等弱结构，使检测框更加稳定；在多车辆场景中，本文方法能够减少暗背景干扰，并保持多个 car 目标的边界可见性。该现象说明，面向检测任务的最优成像结果不一定是视觉上最明亮或最平滑的图像，而是能够在亮度、噪声和局部对比度之间取得任务友好折中的图像。

5 结论

本文提出了一种基于软件定义成像的暗光目标检测框架 SDI-Det。不同于传统暗光增强或检测网络补偿方法, 本文将相机硬件控制、Camera ISP 参数和目标检测反馈统一建模为闭环优化问题, 并通过强化学习 Agent 自适应搜索任务友好的成像参数。为提升训练稳定性和搜索效率, 本文进一步设计渐进式训练策略和分组搜索约束。实验结果表明, SDI-Det 在 Raw COCO 和 LOD 数据集上均优于代表性 baseline, 验证了从成像源头进行任务驱动优化的有效性。本文工作表明, 在复杂暗光场景中, 视觉感知系统不应只优化后端模型, 而应将成像前端作为可定义、可反馈、可优化的主动感知模块。

参考文献

- [1] Yuen Peng Loh and Chee Seng Chan. Getting to Know Low-light Images with The Exclusively Dark Dataset. *Computer Vision and Image Understanding*, 2019.
- [2] Yang Hong, Kaixuan Wei, Linwei Chen, and Ying Fu. Crafting Object Detection in Very Low Light. *British Machine Vision Conference*, 2021.
- [3] Yuanhao Cai, Hao Bian, Jing Lin, Haoqian Wang, Radu Timofte, and Yulun Zhang. Retinexformer: One-stage Retinex-based Transformer for Low-light Image Enhancement. *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2023.
- [4] Wenyu Liu, Gaofeng Ren, Runsheng Yu, Shi Guo, Jianke Zhu, and Lei Zhang. Image-Adaptive YOLO for Object Detection in Adverse Weather Conditions. *Proceedings of the AAAI Conference on Artificial Intelligence*, 2022.
- [5] Yuka Ogino, Yuho Shoji, Takahiro Toizumi, and Atsushi Ito. ERUP-YOLO: Enhancing Object Detection Robustness for Adverse Weather Condition by Unified Image-Adaptive Processing. *arXiv preprint arXiv:2411.02799*, 2024.
- [6] Chen Chen, Qifeng Chen, Jia Xu, and Vladlen Koltun. Learning to See in the Dark. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018.
- [7] Ali Mosleh, Avinash Sharma, Emmanuel Onzon, Fahim Mannan, Nicolas Robidoux, and Felix Heide. Hardware-in-the-Loop End-to-End Optimization of Camera Image Processing Pipelines. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020.
- [8] Ke Yu, Zexian Li, Yue Peng, Chen Change Loy, and Jinwei Gu. ReconfigISP: Reconfigurable Camera Image Processing Pipeline. *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2021.
- [9] Ukcheol Shin, Kyunghyun Lee, and In So Kweon. DRL-ISP: Multi-Objective Camera ISP with Deep Reinforcement Learning. *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2022.

- [10] Yujin Wang, Tianyi Xu, Fan Zhang, Tianfan Xue, and Jinwei Gu. AdaptiveISP: Learning an Adaptive Image Signal Processor for Object Detection. *Advances in Neural Information Processing Systems*, 2024.
- [11] Ziteng Cui and Tatsuya Harada. RAW-Adapter: Adapting Pre-trained Visual Model to Camera RAW Images. *European Conference on Computer Vision*, 2024.
- [12] Ziteng Cui, Jianfei Yang, and Tatsuya Harada. RAW-Adapter: Adapting Pre-trained Visual Model to Camera RAW Images and A Benchmark. *arXiv preprint arXiv:2503.17027*, 2025.
- [13] Zhong-Yu Li, Xin Jin, Boyuan Sun, Chun-Le Guo, and Ming-Ming Cheng. Towards RAW Object Detection in Diverse Conditions. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.
- [14] Jiasheng Guo, Xin Gao, Yuxiang Yan, Guanghao Li, and Jian Pu. Dark-ISP: Enhancing RAW Image Processing for Low-Light Object Detection. *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2025.
- [15] Shani Gamrian, Hila Barel, Feiran Li, Masakazu Yoshimura, and Daisuke Iso. Beyond RGB: Adaptive Parallel Processing for RAW Object Detection. *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2025.
- [16] Xuelin Shen, Haifeng Jiao, Yitong Wang, Yulin He, and Wenhan Yang. End-to-End Low-Light Enhancement for Object Detection with Learned Metadata from RAWs. *Advances in Neural Information Processing Systems*, 2025.
- [17] Kai Chen, Jin Xiao, Leheng Zhang, Kexuan Shi, and Shuhang Gu. Task-Aware Image Signal Processor for Advanced Visual Perception. *arXiv preprint arXiv:2509.13762*, 2025.
- [18] Shuhong Liu, Gengjia Chang, Jun Liu, Xuangeng Chu, Yinqiang Zheng, Tatsuya Harada, and Ziteng Cui. RAWild: Sensor-Agnostic RAW Object Detection via Physics-Guided Curve and Grid Modeling. *arXiv preprint arXiv:2605.05941*, 2026.
- [19] Mishal Fatima, Shashank Agnihotri, Kanchana Vaishnavi Gandikota, Michael Moeller, and Margret Keuper. RAWDet-7: A Multi-Scenario Benchmark for Object Detection and Description on Quantized RAW Images. *arXiv preprint arXiv:2602.03760*, 2026.
- [20] Tsung-Yi Lin, Michael Maire, Serge Belongie, Lubomir Bourdev, Ross Girshick, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C. Lawrence Zitnick. Microsoft COCO: Common Objects in Context. *European Conference on Computer Vision*, 2014.
- [21] Joseph Redmon and Ali Farhadi. YOLOv3: An Incremental Improvement. *arXiv preprint arXiv:1804.02767*, 2018.